

レポート提出票

科目名: 情報工学実験3

実験課題名: 課題2 パターン認識

実施日: 2021年 6月 17日

学籍番号: 4619055

氏名: 辰川力駆

共同実験者:

_____	_____
_____	_____
_____	_____
_____	_____

1 はじめに

パターン認識とは、入力データをあらかじめ定めていた複数のクラスの1つに対応させる処理のことをいう。分類を行うクラスの種類に応じて、パターン認識は大きく、「分類問題」と「予測問題」に分けることができる。また、分類問題、予測問題の両方に関して、「教師あり学習」と「教師なし学習」の2つが存在しており、本実験では、入力データと出力の組みが与えられているデータを利用したパターン認識である「教師あり学習」について理解する。また、「教師あり学習」の代表的な手法であるロジスティック回帰とサポートベクトルマシンについて実装する。

2 レポート課題

2.1 課題 1

課題内容

講義のロジスティック回帰モデルでは、全ての変数を用いたが、モデルに組み込む変数を選択し最適なモデルを選択することができる。変数選択手法に関してどれか一つ調べる。

手順

1. web で変数選択手法について検索する。
2. その変数選択手法に関して Python で実装する。
3. このプログラムを実行する。

結果

変数選択手法として、Wrapper Method について調べた。機械学習モデルを使用して特徴量の組み合わせを評価することで、変数間の関係を探し出し、それぞれのモデルに最適な特徴量の組み合わせを探し出す手法である。

それについて実装したのがソースコード 1 である。結果を比較すると以下の表 1 のようになる。

表 1: ロジスティクス回帰モデルの変数選択をした場合としていない場合

	変数選択なし (すべて使う)	変数選択あり
accuracy	0.78125	0.78125
汎化誤差	0.21875	0.21875
precision	0.72727	0.73810
f1 score	0.64646	0.63918

考察

表 1 より、変数選択なしより変数選択ありのほうが適合率が少しだけ高かった。逆に f1 score は僅かに変数選択なしのほうが高かった。変数選択を実装した場合としない場合でほとんど変わらなかったことから、変数選択を実装しなくても全ての変数を用いた場合で十分にロジスティック回帰で良いモデルを作成できると考える。

2.2 課題 2

課題内容

本実験では線形カーネル関数を用いたサポートベクトルマシンの手法を適用した。課題 2 ではそれ以外のカーネル関数を用いたサポートベクトルマシンについて調査し、実装する。

手順

1. web でカーネル関数を用いたサポートベクトルマシンについて検索する。
2. そのサポートベクトルマシンに関して Python で実装する。
3. このプログラムを実行する。

結果

考察

2.3 課題 3

sklearn.dataset 中にあるワインの品質データ (Wine recognition dataset) を用いて、今回の実験の手法 (ロジスティック、SVM) の中から 2 値分類を行う。

課題内容

手順

結果

考察

2.4 課題 4

課題内容

手順

結果

考察

3 感想

先週の感想でも述べたが、自分的には動画を1つにまとめてくれる方が見やすかった。良かった点としては、前回よりは端的にまとめていたので見返すことがしやすかった。あまり良くなかった点としては、学校に行くのに動画を見るだけなのはあまり良くない考える。

参考文献

- [1] 特徴量選択のまとめ - Qiita

<https://qiita.com/shimopino/items/5fee7504c7acf044a521>

最終閲覧日 2021/06/20

- [2] 変数選択 (Feature Selection) の実装と改善の確認 - 学習する天然ニューラルネット

<https://aotamasaki.hatenablog.com/entry/2018/04/27/222536>

最終閲覧日 2021/06/20

- [3] 【SVM】rbfカーネルのハイパーパラメータをグリッドサーチとベイズ最適化で探す【iris データセット】

https://kenyu-life.com/2019/08/24/rbf_svm_gs/

最終閲覧日 2021/06/20

A 付録

ソースコード 1: レポート課題 1

```
import pandas as pd
import numpy as np
import seaborn as sns
import matplotlib.pyplot as plt
from sklearn.model_selection import train_test_split
from sklearn.metrics import confusion_matrix, accuracy_score, precision_score,
    recall_score, f1_score
from sklearn.metrics import roc_curve, auc
from sklearn.linear_model import LogisticRegression
from sklearn.feature_selection import RFECV

pima = pd.read_csv("data/pima.csv")

X = pima.iloc[:,0:7]
Y = pima["type"].map({'No': 0, 'Yes': 1})

select = RFECV(LogisticRegression(), cv=10, scoring='average_precision')
select.fit(X, Y)
mask = select.support_
X_selected = X.iloc[:,mask]

X_tr, X_te, Y_tr, Y_te = train_test_split(X_selected, Y, test_size=0.3, random_state
    =4619055)

lr = LogisticRegression(C=np.inf,solver='newton-cg')
lr.fit(X_tr, Y_tr)

Y_pred = lr.predict(X_te)

print('confusion_matrix=\n', confusion_matrix(y_true=Y_te, y_pred=Y_pred))
print('accuracy=', accuracy_score(y_true=Y_te, y_pred=Y_pred))
print('汎化誤差=', 1-accuracy_score(y_true=Y_te, y_pred=Y_pred))
print('precision=', precision_score(y_true=Y_te, y_pred=Y_pred))
print('f1_score=', f1_score(y_true=Y_te, y_pred=Y_pred))

Y_score = lr.predict_proba(X_te)[:, 1]
fpr, tpr, thresholds = roc_curve(y_true=Y_te, y_score=Y_score)

plt.plot(fpr, tpr, label='roc_curve(area=%0.3f)' % auc(fpr, tpr))
plt.plot([0, 1], [0, 1], linestyle='--', label='random')
plt.plot([0, 0, 1], [0, 1, 1], linestyle='--', label='ideal')
plt.legend()
plt.xlabel('false_positive_rate')
plt.ylabel('true_positive_rate')
```

ソースコード 2: レポート課題 2

ソースコード 3: レポート課題 3

ソースコード 4: レポート課題 4
